数据获取与清洗

（数据员Charles入职）

>> 今天的学习目标

数据获取与清洗（数据员Charles入职）

- 数据库搭建
- CASE：行情数据采集
- CASE：财务数据采集
- CASE：宏观经济数据采集
- CASE：新闻事件采集与分析
- CASE：机构研报采集
- CASE：财经日历采集
- CASE：大模型驱动的催化剂事件

数据库搭建

为什么AI量化需要用数据库

Thinking：为什么AI量化需要使用数据库？

很多同学初学时喜欢把数据存成 Excel 或 CSV，但在真正的 AI 实战中，你会遇到三个死胡同：

- 并发冲突：

当你开启 8 个线程同时从 QMT 下载 5000 只股票数据时，CSV 文件会被锁死导致报错，而 MySQL 支持多线程同时暴力写入。

- 去重难题：

新闻和研报数据每天都在更新，CSV 很难判断哪条存过。数据库可以通过唯一索引实现自动去重。

- 查询速度：

想找“过去 3 年所有 ROE > 15% 的股票”，SQL 语句毫秒级返回，CSV 需要把几 GB 数据全读进内存，电脑直接卡死。

存储方案对比

方案	优点	缺点	适用人群 / 场景
CSV 文件	简单直观，Excel 可读	无法去重，并发写入会冲突，查询大文件极慢。	偶尔跑一次的小实验，数据静态备份。
SQLite	无需安装配置，单文件存储，读性能远超 CSV。	写入并发性能差，不适合高频实时采集。	零基础上手，单机回测，轻量化策略。
MySQL 8.0	工业级标准，并发处理能力强，支持窗口函数。	存储上亿级时序数据时性能下降，扩展性一般。	搭建长期稳定系统，多策略并行运行。
PostgreSQL	时序数据王者（支持 TimescaleDB），功能最强。	配置略复杂，对 SQL 优化能力有一定要求。	处理 Tick/高频数据。
向量数据库	支持语义搜索，专为 AI 研报、新闻分析设计。	需配合 Embedding 模型使用。	构建智能投研、RAG 系统。

如果你不想折腾安装环境，也可以先使用SQLite，先把逻辑跑通

认识数据库：SQL vs NoSQL

在量化世界里，我们通常会接触到两种数据库：

- 关系型数据库 (SQL, 如 MySQL)：

像 Excel 一样有严格的表结构（行和列）。适合存结构化数据，比如：股价、财务报表、宏观指标。

- 非关系型数据库 (NoSQL, 如 MongoDB)：

像存文件夹。适合存非结构化数据，比如：研报全文、原始网页抓取等。

在 AI 量化中（机器学习），80%场景都在处理价格和指标，可以使用MySQL 8.0，或者 PostgreSQL（PG）

认识数据库：PostgreSQL

MySQL 8.0 增加了窗口函数，可以处理基础场景，但 PG 在量化中有三个降维打击的优势：

- TimescaleDB 插件（核心神器）： 这是基于 PG 的时序数据库插件。它能把普通表变成超表（Hypertables），处理亿级行数据的 OHLCV 或 Tick 数据时，查询性能比 MySQL 快一个数量级。
- 更强的计算与索引： PG 支持 GiST、GIN 等复杂索引，而且对复杂子查询和 CTE（通用表表达式）的优化更聪明，非常适合在数据库内直接完成一部分机器学习的特征预处理。
- 插件生态： PG 支持 PL/Python，你甚至可以在 SQL 里直接运行 Python 代码；还有 pgvector 插件，能直接存向量。

在AI量化领域，PostgreSQL是不错的选择，适合专业量化机构；
我们先用MySQL 8.0处理基础数据，后续如果处理高频/海量时序数据，可以直接上 PostgreSQL + TimescaleDB。
从MySQL到PostgreSQL语法基本上一致，迁移成本低

认识数据库：向量数据库

向量数据库（Vector Database）：

被看做 NoSQL 家族的一个重要分支，但在现代 AI 架构中，它正逐渐独立出来，成为与 SQL、NoSQL 并列的第三大支柱。

在课程中，把向量检索单独列看做AI 时代的基础设施：

- FAISS： 在本地脚本或轻量化 Demo 中使用（即插即用）。
- Elasticsearch： 在需要全文搜索 + 向量搜索混搭的大型系统中使用。
- 专有向量数据库 (Milvus/Chroma)： 推荐在构建大规模 RAG（检索增强生成）系统时使用。

MYSQL下载与使用

下载地址：https://dev.mysql.com/downloads/installer/

推荐下载 Windows 版的 Installer

1. 打开安装包，选择 Custom（自定义安装），只勾选以下两项：

   - MySQL Server 8.x -- 数据库服务

   - MySQL Shell -- 命令行工具（可选，后面也可以用其他工具代替）

2. 一路 Next，到配置页面时注意以下设置

配置项	推荐值	说明
Config Type	Development Computer	开发用途，占用资源少
Port	3306	默认端口，不需要改
Character Set	utf8mb4	支持中文和特殊字符，必须选这个
Root Password	自己设一个	记住这个密码，后面配置 .env 要用

MYSQL下载与使用

连接MYSQL的方式：

方式一：命令行（MySQL Shell 或 CMD）

安装完成后，MySQL 会自动加入系统 PATH。打开 CMD 或 PowerShell：

mysql -u root –p

输入安装时设置的 root 密码，看到 `mysql>` 提示符就说明连接成功了。

如果提示 mysql 不是内部命令，需要手动将 MySQL 的 bin 目录加到系统 PATH：

默认安装路径

C:\Program Files\MySQL\MySQL Server 8.0\bin

MYSQL下载与使用

方式二：Navicat / DBeaver（推荐）

图形化工具，操作直观，适合日常查看数据。

- Navicat：商业软件，有 14 天试用

- DBeaver：免费开源，功能够用

MYSQL下载与使用

Step1，创建数据库

连上 MySQL 后（命令行或图形工具），执行：

```
CREATE DATABASE IF NOT EXISTS wucai_trade

DEFAULT CHARACTER SET utf8mb4

DEFAULT COLLATE utf8mb4_unicode_ci;
```

MYSQL下载与使用

Step2，执行建表脚本

在 CMD 或 PowerShell 中执行（注意替换密码和路径）

```
mysql -u root -p wucai_trade < "./wucai_trade_charles.sql"
```

输入密码后，如果没有任何输出就表示执行成功。

图形工具方式（Navicat / DBeaver）：

1. 左侧选中 wucai_trade 数据库
2. 打开 SQL 编辑器（Navicat: 查询 -> 新建查询；DBeaver: SQL 编辑器）
3. 把 wucai_trade_charles.sql 文件内容粘贴进去
4. 点击"运行"

量化交易的核心表设计（7张）

在 database_trade.sql 中，我设计了 7 张表

- trade_stock_daily (日K线)：每只股票每天一条，用于训练价格预测模型。
- trade_stock_financial (季度财务)：每只股票每个报告期一条，捕获 ROE、毛利率等基本面信号。
- trade_macro_indicator (月度宏观)：CPI、PPI、PMI 等，判断大盘牛熊环境。
- trade_rate_daily (日度利率)：中美国债收益率，AI 捕捉资金流动性的关键。
- trade_stock_news (个股新闻)：用于 NLP 情感分析，捕捉突发利好/利空。
- trade_report_consensus (机构研报)：挖掘券商一致预期与实际表现的偏差。
- trade_calendar_event (财经日历)：记录两会、美联储议息等重要时间窗口。

=> 构成了 AI 训练的完整特征库

数据表：trade_stock_daily (日K线)

```sql
-- 日K线数据表 (核心行情数据，数据量最大)
CREATE TABLE IF NOT EXISTS trade_stock_daily (
    id INT AUTO_INCREMENT PRIMARY KEY,
    stock_code VARCHAR(20) NOT NULL COMMENT '股票代码',
    trade_date DATE NOT NULL COMMENT '交易日期',
    open_price DECIMAL(10,2) COMMENT '开盘价',
    high_price DECIMAL(10,2) COMMENT '最高价',
    low_price DECIMAL(10,2) COMMENT '最低价',
    close_price DECIMAL(10,2) COMMENT '收盘价(前复权)',
    volume BIGINT COMMENT '成交量(股)',
    amount DECIMAL(20,2) COMMENT '成交额(元)',
    turnover_rate DECIMAL(10,4) COMMENT '换手率',
    created_at DATETIME DEFAULT CURRENT_TIMESTAMP,
    UNIQUE KEY idx_stock_daily_code_date (stock_code, trade_date),
    KEY idx_stock_daily_code (stock_code),
    KEY idx_stock_daily_date (trade_date)
) ENGINE=InnoDB DEFAULT CHARSET=utf8mb4 COMMENT='日K线数据';
```

database_trade.sql

数据表：trade_stock_financial (季度财务)

```sql
-- 季度财务数据表
CREATE TABLE IF NOT EXISTS trade_stock_financial (
  id INT AUTO_INCREMENT PRIMARY KEY,
  stock_code VARCHAR(20) NOT NULL,
  report_date DATE NOT NULL COMMENT '报告期，如 2024-12-31',
  revenue DECIMAL(20,2) COMMENT '营业收入(元)',
  net_profit DECIMAL(20,2) COMMENT '净利润(元)',
  eps DECIMAL(10,4) COMMENT '每股收益',
  roe DECIMAL(10,4) COMMENT 'ROE(%)',
  roa DECIMAL(10,4) COMMENT 'ROA(%)',
  gross_margin DECIMAL(10,4) COMMENT '毛利率(%)',
  net_margin DECIMAL(10,4) COMMENT '净利率(%)',
  debt_ratio DECIMAL(10,4) COMMENT '资产负债率(%)',
  current_ratio DECIMAL(10,4) COMMENT '流动比率',
  operating_cashflow DECIMAL(20,2) COMMENT '经营现金流(元)',
  total_assets DECIMAL(20,2) COMMENT '总资产(元)',
  total_equity DECIMAL(20,2) COMMENT '净资产(元)',
  data_source VARCHAR(20) DEFAULT 'akshare',
  created_at DATETIME DEFAULT CURRENT_TIMESTAMP,
  UNIQUE KEY idx_fina_code_date (stock_code, report_date),
  KEY idx_fina_code (stock_code)
) ENGINE=InnoDB DEFAULT CHARSET=utf8mb4 COMMENT='季度财务数据';
```

database_trade.sql

数据表：trade_macro_indicator (月度宏观)

```sql
-- 月度宏观指标表
CREATE TABLE IF NOT EXISTS trade_macro_indicator (
  id INT AUTO_INCREMENT PRIMARY KEY,
  indicator_date DATE NOT NULL COMMENT '指标月份(月末日期)',
  cpi_yoy DECIMAL(10,2) COMMENT 'CPI同比(%)',
  ppi_yoy DECIMAL(10,2) COMMENT 'PPI同比(%)',
  pmi DECIMAL(10,2) COMMENT 'PMI',
  m2_yoy DECIMAL(10,2) COMMENT 'M2同比增速(%)',
  shrzgm DECIMAL(14,0) COMMENT '社融规模增量(亿元)',
  lpr_1y DECIMAL(6,2) COMMENT 'LPR 1年期(%)',
  lpr_5y DECIMAL(6,2) COMMENT 'LPR 5年期(%)',
  data_source VARCHAR(20) DEFAULT 'akshare',
  created_at DATETIME DEFAULT CURRENT_TIMESTAMP,
  UNIQUE KEY idx_macro_date (indicator_date)
) ENGINE=InnoDB DEFAULT CHARSET=utf8mb4 COMMENT='月度宏观指标';
```

database_trade.sql

数据表：trade_rate_daily (日度利率)

```sql
-- 日频利率指标表(国债收益率等)
CREATE TABLE IF NOT EXISTS trade_rate_daily (
  id INT AUTO_INCREMENT PRIMARY KEY,
  rate_date DATE NOT NULL COMMENT '日期',
  cn_bond_10y DECIMAL(8,4) COMMENT '中国10年期国债收益率(%)',
  us_bond_10y DECIMAL(8,4) COMMENT '美国10年期国债收益率(%)',
  data_source VARCHAR(20) DEFAULT 'akshare',
  created_at DATETIME DEFAULT CURRENT_TIMESTAMP,
  UNIQUE KEY idx_rate_date (rate_date)
) ENGINE=InnoDB DEFAULT CHARSET=utf8mb4 COMMENT='日频利率指标';
```

database_trade.sql

数据表：trade_stock_news (个股新闻)

```
-- 新闻事件表
CREATE TABLE IF NOT EXISTS trade_stock_news (
  id INT AUTO_INCREMENT PRIMARY KEY,
  stock_code VARCHAR(20) COMMENT '股票代码',
  sector_code VARCHAR(20) COMMENT '板块代码',
  news_type VARCHAR(20) NOT NULL COMMENT
'announcement/news/report',
  title VARCHAR(500) NOT NULL,
  content TEXT,
  summary TEXT,
  source VARCHAR(50) COMMENT 'eastmoney/cailianshe/kimi',
  source_url VARCHAR(500),
  published_at DATETIME,
  sentiment VARCHAR(20) COMMENT 'positive/negative/neutral',
  sentiment_score DECIMAL(5,2) COMMENT '-1到1',
  is_important TINYINT DEFAULT 0,
  is_read TINYINT DEFAULT 0,
  created_at DATETIME DEFAULT CURRENT_TIMESTAMP,
  KEY idx_stock_news_code (stock_code),
  KEY idx_stock_news_published (published_at),
  KEY idx_stock_news_type (news_type)
) ENGINE=InnoDB DEFAULT CHARSET=utf8mb4 COMMENT='新闻事件';
```

database_trade.sql

数据表：trade_report_consensus (机构研报)

```sql
-- 研报一致性预期表
CREATE TABLE IF NOT EXISTS trade_report_consensus (
    id INT AUTO_INCREMENT PRIMARY KEY,
    stock_code VARCHAR(20) NOT NULL,
    broker VARCHAR(50) COMMENT '券商',
    report_date DATE,
    rating VARCHAR(20) COMMENT '买入/增持/中性/减持',
    target_price DECIMAL(10,2),
    eps_forecast_current DECIMAL(10,4) COMMENT '当年EPS预测',
    eps_forecast_next DECIMAL(10,4) COMMENT '次年EPS预测',
    revenue_forecast DECIMAL(20,2) COMMENT '营收预测(亿)',
    source_file VARCHAR(500) COMMENT 'PDF文件路径',
    created_at DATETIME DEFAULT CURRENT_TIMESTAMP,
    UNIQUE KEY idx_consensus_unique (stock_code, broker, report_date),
    KEY idx_consensus_code (stock_code)
) ENGINE=InnoDB DEFAULT CHARSET=utf8mb4 COMMENT='研报一致性预期';
```

database_trade.sql

数据表：trade_calendar_event (财经日历)

```
-- 财经日历事件表
CREATE TABLE IF NOT EXISTS trade_calendar_event (
  id INT AUTO_INCREMENT PRIMARY KEY,
  event_date DATE NOT NULL COMMENT '事件日期',
  event_time VARCHAR(10) COMMENT '事件时间(HH:MM)',
  country VARCHAR(10) NOT NULL DEFAULT 'CN' COMMENT 'CN/US/EU/JP',
  category VARCHAR(30) NOT NULL COMMENT
'rate/inflation/employment/gdp/pmi/trade/policy/other',
  title VARCHAR(200) NOT NULL,
  importance TINYINT DEFAULT 2 COMMENT '1=低 2=中 3=高',
  previous_value VARCHAR(50) COMMENT '前值',
  forecast_value VARCHAR(50) COMMENT '预测值',
  actual_value VARCHAR(50) COMMENT '实际值',
  impact VARCHAR(200) COMMENT '市场影响说明',
  ai_prompt TEXT COMMENT 'AI提问prompt',
  source VARCHAR(50) COMMENT 'eastmoney/fred/manual',
  source_url VARCHAR(500),
  is_recurring TINYINT DEFAULT 0,
  recurrence_rule VARCHAR(100) COMMENT '周期规则，如"每月第
一个周五"',
  status VARCHAR(20) DEFAULT 'upcoming' COMMENT
'upcoming/released/cancelled',
  created_at DATETIME DEFAULT CURRENT_TIMESTAMP,
  updated_at DATETIME DEFAULT CURRENT_TIMESTAMP ON UPDATE
CURRENT_TIMESTAMP,
  UNIQUE KEY idx_calendar_date_title (event_date, title),
  KEY idx_calendar_date (event_date),
  KEY idx_calendar_country (country),
  KEY idx_calendar_category (category),
  KEY idx_calendar_importance (importance)
) ENGINE=InnoDB DEFAULT CHARSET=utf8mb4 COMMENT='财经日历
事件';
```

database_trade.sql

核心设计模式：幂等性写入

数据采集系统的重要设计：ON DUPLICATE KEY UPDATE。

```
INSERT INTO trade_stock_daily (stock_code, trade_date, close_price)VALUES ('600519.SH', '2026-02-24', 1468.02)ON DUPLICATE KEY UPDATE close_price = VALUES(close_price);
```

执行逻辑如下：

- 尝试 INSERT：数据库先尝试插入这条记录（600519.SH, 2026-02-24, 1468.02）
- 冲突检测：如果 (stock_code, trade_date) 这个组合已经存在（违反了主键或唯一索引约束），则不报错，转而执行 UPDATE
- 执行更新：将现有记录的 close_price 更新为新值 1468.02（VALUES(close_price) 指代的是 INSERT 语句中传入的值）

第一次执行：记录不存在 → 插入新记录 → 数据库状态：价格 = 1468.02

第二次执行：记录已存在 → 更新为相同值 1468.02 → 数据库状态：价格 = 1468.02

第一万次执行：同上 → 数据库状态：价格 = 1468.02

幂等性写入指的是：无论你执行一次写入操作，还是重复执行一万次相同的写入操作，数据库的最终状态都是完全一致的。

核心设计模式：幂等性写入

Thinking：为什么幂等性对量化很重要？

- 断点续传

脚本采集 5000 只股票，跑一半断网了。你重新运行，它会自动识别：存过的更新（无害），没存的插入（补全）。

- 数据修正

交易所偶尔会修正历史错数，该模式能确保你的数据库始终与源头同步，不需要先删表再重下。

安全工程：环境变量管理

在项目根目录创建一个 .env 文件：

```
WUCAI_SQL_HOST=localhost
WUCAI_SQL_PASSWORD=你的真实密码
DASHSCOPE_API_KEY=sk-xxxx...
```

安全：上传代码到 Git 或分享给别人时，不带 .env 文件 => 密码不会泄露。

灵活：本地测试和服务器上运行，只需改 .env，=> 不需要动代码。

代码读取逻辑：

```
from dotenv import load_dotenv
load_dotenv()  # 自动加载环境变量

DB_CONFIG = {
    'host': os.getenv('WUCAI_SQL_HOST'),
    'password': os.getenv('WUCAI_SQL_PASSWORD'),
    # ...
}
```

永远不要把你的数据库密码写在 Python 代码里 => 正确姿势：使用 .env 文件

db_config.py

Python 数据库连接小技巧

在 db_config.py 中，我们封装了 execute_query 函数。

使用 DictCursor

- 普通 Cursor：返回 ('600519.SH', 1468.02)，你得数第几个是价格，代码很难懂。
- DictCursor：返回 {‘stock_code’: ‘600519.SH’, ‘close_price’: 1468.02}。你可以直接用 row[‘close_price’] 拿数据 => 使用方便

db_config.py

CASE：行情数据采集

行情数据采集

Thinking：为什么选择 MiniQMT 作为行情数据源?

获取数据的方法很多（如 AkShare, Tushare），但为什么要使用 MiniQMT?

- 极速本地化：MiniQMT 连接的是券商真实的行情服务器，数据下载到本地缓存后，读取速度很快。
- 全量 A 股支持：支持沪深京全量约 5000 只股票的日线、分钟线甚至是逐笔 Tick 数据。
- 免费且专业：只开通券商QMT，就能使用等同于 Wind、Choice 等万级收费终端的数据服务。

```
from xtquant import xtdata
xtdata.connect()  # 连接本地QMT服务
all_codes = xtdata.get_stock_list_in_sector('沪深A股')  # 一行代码拿全 A 列表
```

前复权：消除股价跳空

Thinking：如果不复权，会怎样?

如果你不处理复权，你的 AI 会在分红送股当天认为股票暴跌了。

Thinking：什么是前复权?

假设某股票价格 100 元，今天每 10 股送 10 股（高送转），明天股价会变成 50 元。

- 不复权：曲线会出现一个巨大的缺口，AI 会判定为跌停。
- 前复权：以今天的价格（50元）为基准，把历史价格全部按比例缩小

=> 这样曲线就是平滑连续的。

高送转是A股市场的一个特定术语，指高比例送红股和转增股本的统称 => 降低股价门槛，制造便宜错觉

前复权：消除股价跳空

Thinking：量化回测要采用哪种复权方式?

前复权，保持当前价格真实 => 回测计算出的今天该买多少手是基于当前实际股价的。

技术指标不失真：均线、MACD 等指标是基于连续价格计算的

```
# dividend_type='front' 表示前复权
data = xtdata.get_market_data_ex(
    stock_list=[stock_code],
    period='1d',
    dividend_type='front'
)
```

1-行情数据采集.py

高效采集：增量更新

Thinking：全量 A 股有 300 多万条日线数据，如何更新更合理？

每天重下是不现实的 => 需要采用增量策略。

- 批量查询：

先用一条 SQL 批量查出每只股票在库里的最新日期，避免 5000 次单独查询。

对每只股票，如果最新日期已经是今天，则跳过；

否则以该日期为起点增量下载并写入，用 ON DUPLICATE KEY UPDATE 覆盖当天旧数据。

=> 这样每天只需拉取缺失或未完成的数据，而不是重下全部 300 多万条

高效采集：增量更新

```
def get_existing_latest_dates():
    """一次性查询所有股票在DB中的最新交易日，返回 {stock_code: 'YYYYMMDD'}"""
    rows = execute_query(
        "SELECT stock_code, MAX(trade_date) AS max_date FROM trade_stock_daily GROUP BY stock_code"
    )
    result = {}
    for r in rows:
        if r['max_date']:
            result[r['stock_code']] = r['max_date'].strftime('%Y%m%d')
    return result
```

1-行情数据采集.py

换手率计算：洞察资金动向

QMT 提供的原始数据不含换手率，我们需要根据流通股本自行计算。

TurnoverRate = Volume * 100 / FloatingShares * 100%

QMT 的 volume 单位是手，计算时需要乘以 100 转为股。

Thinking：什么时候使用换手率?

换手率是 AI 筛选妖股或活跃股的重要特征。

=> 换手率突增往往意味着主力进场或重大消息刺激。

换手率计算：洞察资金动向

```
float_shares = _get_float_shares(stock_code)


rows = []
for idx, row in df.iterrows():
    idx_str = str(idx)
    if len(idx_str) >= 8:
        trade_date = f"{idx_str[:4]}-{idx_str[4:6]}-{idx_str[6:8]}"
        vol = int(row['volume'])
        # xtdata volume 单位是手(1手=100股)，流通股本单位是股
        vol_shares = vol * 100
        turnover = round(vol_shares / float_shares * 100, 4) if float_shares > 0 and vol > 0 else None
        rows.append((
            stock_code, trade_date,
            float(row['open']), float(row['high']),
            float(row['low']), float(row['close']),
            vol, float(row['amount']),
            turnover,
        ))
```

1-行情数据采集.py

多线程 + 批量写入

Thinking：如何让 5000+ 只股票的采集在几分钟内完成?

- 多线程并行 (ThreadPoolExecutor)

开启 8 个线程同时向 QMT 请求数据。由于网络请求和文件 I/O 是耗时大户，多线程可以将速度提升数倍。

- 批量写入 (executemany)

不要在循环里写 INSERT。

错误做法：循环 1000 次，执行 1000 次写入，数据库会因为频繁建立连接而崩溃。

正确做法：将 1000 条数据打包成一个大列表，一次性塞给数据库。这种方式比逐条写入快 10+ 倍。

```
# 将 rows 列表一次性写入
cursor.executemany(INSERT_SQL, rows)
```

1-行情数据采集.py

Summary（行情数据采集）

Step1，连接 QMT：连接 MiniQMT 数据服务，并获取沪深 A 股股票列表（约 5000 只）。

Step2，批量查最新日期

用一条 SQL 查询每只股票在库中的最新交易日，得到 {stock_code: max_date} 映射。

Step3，决定是否采集

若某只股票的最新日期已是今天，则跳过；否则将该日期作为增量下载起点（无历史数据时从 2023-01-01 起）。

Step4，增量下载

调用 xtdata.download_history_data 和 get_market_data_ex，按股票从起始日期拉取日线（开高低收、成交量、成交额），并计算换手率。

Step5，写入数据库：使用 INSERT ... ON DUPLICATE KEY UPDATE 写入 trade_stock_daily，多线程并行处理。

Step6，输出统计：打印成功/失败数量，以及数据库概况。

1-行情数据采集.py

打卡：行情数据采集

使用你的miniQMT进行行情数据采集

- 这里会使用 数据表 trade_stock_daily （日线）

id	stock_code	trade_date	open_price	high_price	low_price	close_price	volume	amount	turnover_rate	created_at
1	600519.SH	2025-01-02	1524.00	1524.49	1480.00	1488.00	50029	)883773.00	0.3995	2026-02-03 1
2	600519.SH	2025-01-03	1494.50	1494.99	1467.01	1475.00	32628	5610288.00	0.2606	2026-02-03 1
3	600519.SH	2025-01-06	1453.00	1462.66	1432.80	1440.00	44255	2479712.00	0.3534	2026-02-03 1
4	600519.SH	2025-01-07	1444.66	1451.89	1439.00	1440.20	24221	4634227.00	0.1934	2026-02-03 1
5	600519.SH	2025-01-08	1440.00	1451.82	1426.66	1442.50	35258	1821246.00	0.2816	2026-02-03 1
6	600519.SH	2025-01-09	1448.99	1464.58	1432.98	1444.00	29706	5852736.00	0.2372	2026-02-03 1
7	600519.SH	2025-01-10	1447.10	1451.95	1436.00	1436.00	21872	4677598.00	0.1747	2026-02-03 1
8	600519.SH	2025-01-13	1425.00	1444.44	1422.01	1443.98	21083	)806870.00	0.1684	2026-02-03 1
9	600519.SH	2025-01-14	1444.95	1478.68	1442.00	1472.50	30957	5651504.00	0.2472	2026-02-03 1
10	600519.SH	2025-01-15	1467.00	1474.60	1460.01	1471.27	18399	1518712.00	0.1469	2026-02-03 1
11	600519.SH	2025-01-16	1474.00	1482.66	1442.00	1446.38	26342	)411437.00	0.2104	2026-02-03 1
12	600519.SH	2025-01-17	1446.39	1461.00	1446.38	1454.75	18309	3227309.00	0.1462	2026-02-03 1
13	600519.SH	2025-01-20	1461.00	1489.79	1460.00	1474.80	31410	7626351.00	0.2508	2026-02-03 1
14	600519.SH	2025-01-21	1481.00	1482.00	1465.00	1468.15	16856	1821229.00	0.1346	2026-02-03 1
15	600519.SH	2025-01-22	1463.27	1467.95	1438.00	1441.00	28294	3101682.00	0.2259	2026-02-03 1
16	600519.SH	2025-01-23	1449.97	1468.00	1438.00	1443.00	27125	2700850.00	0.2166	2026-02-03 1
17	600519.SH	2025-01-24	1442.00	1447.79	1430.31	1436.00	31360	5322685.00	0.2504	2026-02-03 1
18	600519.SH	2025-01-27	1437.00	1443.97	1427.02	1434.99	29356	3534543.00	0.2344	2026-02-03 1
19	600519.SH	2025-02-05	1440.00	1443.00	1402.21	1403.80	40757	3730033.00	0.3255	2026-02-03 1
20	600519.SH	2025-02-06	1400.01	1421.99	1400.01	1412.84	27356	9568163.00	0.2185	2026-02-03 1
21	600519.SH	2025-02-07	1413.68	1442.68	1403.41	1436.00	37242	)850624.00	0.2974	2026-02-03 1

CASE：财务数据采集

核心财务指标：AI 选股的特征工程

在 AI 模型中，我们不直接喂入原始报表，而是提取经过行业验证的核心衍生指标。

Thinking：三大报表的逻辑关联是怎样的？

- 利润表：反映赚了多少，是阶段性的成果。
- 资产负债表：反映家底有多少，是此时此刻的财务状态。
- 现金流量表：反映血量是否安全，是维持生存的血液循环。

Thinking：一家公司利润表显示赚了 1 亿，但现金流量表显示经营现金流是负5000 万。你觉得这个利润质量如何？

AI 会敏锐捕捉到这种质量低下的利润 => 看做是潜在利空信号。

利润都卡在应收账款（赊销没收款）和存货（积压占资金）里，没变成真金白银。典型纸面富贵，盈利质量差，有虚增利润或资金链断裂风险。

财务指标提取

Thinking：QMT 返回的原始数据字段繁杂，而且各股票可能存在差异（如字段名不同），如何设计更鲁棒？

(1) 多候选字段查找 (get_field)

由于数据源字段可能变更，我们通过列表形式进行优先级匹配

```
# 提取净利润：优先用含少数股东损益的，没有再用不含的
net_profit = get_field(inc, ['net_profit_incl_min_int_inc', 'net_profit_excl_min_int_inc'])
```

(2) 针对缺失的衍生指标，需要手动计算兜底

如果数据源缺失衍生指标，需要写代码自动计算

注：safe_divide 内部处理了分母为 0 的异常情况，防止程序崩溃。

```
# 自行计算 ROA (净利润 / 总资产)
roa = safe_divide(net_profit, total_assets, pct=True)
```

财务指标提取

```
def extract_periods(data, stock_code):
    """从xtquant财务数据中提取核心指标"""
    # 四张报表各自按报告期整理
    pershare_map = build_period_map(stock_data.get('PershareIndex', []))
    balance_map  = build_period_map(stock_data.get('Balance', []))
    income_map   = build_period_map(stock_data.get('Income', []))
    cashflow_map = build_period_map(stock_data.get('CashFlow', []))

    for period in all_periods:
        # EPS 直接从每股指标表取
        eps = get_field(ps, ['s_fa_eps_basic'])

        # ROE: 优先从每股指标表取，没有则手动算 净利润/净资产
        roe = get_field(ps, ['du_return_on_equity'])
        if roe is None and net_profit and total_equity:
            roe = safe_divide(net_profit, total_equity, pct=True)
```

```
        # 毛利率: 优先取现成值，没有则 (营收-成本)/营收
        gross_margin = get_field(ps, ['sales_gross_profit'])
        if gross_margin is None and revenue and operating_cost:
            gross_margin = round((revenue - operating_cost) / revenue * 100, 4)
```

2-财务数据采集.py

性能优化：50 只/批 批量下载

Thinking：A股的财务数据量非常大，如何下载更合理?

- 传统方式：逐只股票调用 API。5000 只股票需要数小时。
- 代码优化：设置 BATCH_SIZE = 50。

一次 API 调用下载 50 只股票的所有报表（资产负债、利润、现金流、每股指标、股本）。

这种方式将耗时缩短了约 10 倍，只需 15 分钟左右即可同步全量历史财务数据。

这里没有用多线程采集，QMT 的 download_financial_data2 和 get_financial_data 支持一次传入多只股票（stock_list=batch_codes）

- 逐只调用：5000 只股票 = 5000 次 API 调用
- 批量调用：每批 50 只 = 约 100 次 API 调用

断点续传与幂等性设计

采集千万级数据时，断网或系统崩溃是常态。

- 去重逻辑

程序启动前先查询数据库中已有的股票：SELECT DISTINCT stock_code FROM trade_stock_financial。

- 增量跳过

已采集过的股票直接从待处理列表中移除，实现断点续传。

- 覆盖写入

使用 ON DUPLICATE KEY UPDATE。

=> 如果交易所修正了某份财报（如年报修正），重新跑一次脚本即可自动更新数据库中的旧值，无需删表。

Summary（财务数据采集）

Step1，连接 QMT：连接 MiniQMT 并获取沪深 A 股股票列表。

Step2，查询已采集：用一条 SQL 查出已有财务数据的股票，跳过这些股票（断点续传）。

Step3，批量下载：

每批 50 只股票，调用 xtdata.download_financial_data2 拉取资产负债表、利润表、现金流量表、每股指标等。

Step4，解析与计算：

按报告期从各表取数，计算 ROE、ROA、毛利率、净利率、资产负债率、流动比率、经营现金流等，合并为一条条记录。

Step4，写入数据库：

使用 INSERT ... ON DUPLICATE KEY UPDATE 写入 trade_stock_financial，并输出统计信息。

2-财务数据采集.py

打卡：财务数据采集

使用你的miniQMT进行财务数据采集

- 这里会使用 数据表 trade_stock_financial (季度财务)

id	stock_code	report_date	revenue	net_profit	eps	roe	roa	gross_margin	net_margin	debt_ratio	current_ratio
23	600519.SH	2006-06-30	2013492528.06	603117899.92	0.6100	12.0580	7.7324	83.3698	29.9538	35.1466	2.0196
24	600519.SH	2006-09-30	3252383811.75	1056601132.65	1.0700	19.7710	11.9981	83.5495	32.4870	38.5103	1.8742
25	600519.SH	2006-12-31	4903375765.41	1616375200.07	1.6400	26.6578	16.8886	83.9592	32.9645	35.5555	1.9891
26	600519.SH	2007-03-31	1587538095.68	561440706.10	0.5700	9.6459	5.6807	85.0268	35.3655	40.4210	1.7617
27	600519.SH	2007-06-30	2629088876.42	893948241.41	0.9000	14.5740	8.7411	85.1958	34.0022	39.1859	1.8151
28	600519.SH	2007-09-30	4458382249.26	1669221956.18	1.6900	24.2809	16.3742	85.1373	37.4401	31.7955	2.1930
29	600519.SH	2007-12-31	7237430747.12	2966052508.95	3.0000	36.0215	28.2981	87.9565	40.9821	20.1557	3.7415
30	600519.SH	2008-03-31	1993496395.46	917048744.59	0.9300	10.0692	7.9351	89.9267	46.0020	19.6501	3.6190
31	600519.SH	2008-06-30	4619717309.60	2351939273.63	2.3700	24.2851	20.8577	90.4311	50.9109	12.6060	5.4521
32	600519.SH	2008-09-30	6486517281.01	3304198781.00	3.3300	31.2011	25.4376	90.5197	50.9395	16.8017	4.2386
33	600519.SH	2008-12-31	8241685564.11	4000759343.11	4.0300	35.5795	25.3949	90.2967	48.5430	26.9818	2.8797
34	600519.SH	2009-03-31	2512537167.20	1278840567.82	1.2900	10.2623	8.1843	89.9923	50.8984	19.3114	3.9557
35	600519.SH	2009-06-30	5546006031.29	2928842256.25	2.9600	22.6274	18.3353	90.4144	52.8099	17.5712	4.3682
36	600519.SH	2009-09-30	7807202385.78	3979795618.20	4.0100	28.5485	23.7771	90.4805	50.9760	15.0691	5.1129
37	600519.SH	2009-12-31	9669999065.39	4552888944.00	4.5700	31.4731	23.0297	90.1688	47.0826	25.8885	3.0649
38	600519.SH	2010-03-31	3039906100.41	1344382797.81	1.3400	8.5457	6.5804	90.2830	44.2245	21.7040	3.6632
39	600519.SH	2010-06-30	6587266362.78	3274562600.07	3.2800	19.9094	15.3492	91.3592	49.7105	21.5461	3.6156
40	600519.SH	2010-09-30	9327577784.12	4411104477.83	4.0200	25.1750	19.3384	91.1950	47.2910	22.3071	3.5358
41	600519.SH	2010-12-31	11633283740.18	5339761496.97	4.8700	29.0224	20.8686	90.9490	45.9007	27.5063	2.8884
42	600519.SH	2011-03-31	4220589097.94	1991291329.64	1.8100	9.8177	6.8284	90.7107	47.1804	29.5628	2.7589
43	600519.SH	2011-06-30	9825823427.08	5166306192.53	4.7300	24.4441	16.7085	91.3995	52.5789	30.3207	2.7224
44	600519.SH	2011-09-30	13642075480.07	6930714312.61	6.3300	30.4017	21.0697	91.5273	50.8040	29.8243	2.7563
45	600519.SH	2011-12-31	18402355207.30	9250323807.62	8.4400	37.0144	26.5046	91.5705	50.2671	27.2128	2.9354

CASE：宏观经济数据采集

宏观经济数据采集

Thinking：为什么 AI 量化需要宏观数据?

在金融领域，有一个经典的自上而下 (Top-Down) 分析框架。AI 模型如果不输入宏观特征，就无法理解为什么同样的财务表现，在不同年份股价表现天差地别。

- 锚定定价：10 年期国债收益率被誉为全球资产定价之锚。它上涨，股市的估值往往就会承压。
- 捕捉拐点：PMI 指标通常领先于 GDP 公布，是判断经济复苏的温度计。
- 钱的流向：M2（广义货币）增速告诉我们，市场上流动的水变多了还是变少了。

在量化投资中，如果个股行情是海浪，那么宏观经济就是潮汐。
不看宏观，就像是在台风天强行出海。

特斯拉的2021年 vs 2022年

2021年，特斯拉净利润55亿美元，10年期美债收益率维持在1.5%低位，市场给予其超200倍PE估值，股价一度冲上400美元（拆股前）。

到2022年，特斯拉净利润增长至126亿美元（翻倍），财务表现更优，但美联储激进加息导致10年期美债收益率飙升至4.3%，高估值资产遭遇杀估值，特斯拉PE跌至30倍，股价反而暴跌65%至120美元。

Thinking：这是为什么？

同样的盈利增速，在水牛（流动性泛滥）环境下是利好，在紧缩环境下却成利空

=> AI量化需要了解当前的宏观利率数据，否则模型会误判2022年的暴跌为基本面恶化

=> 实际上是分母端（贴现率）的宏观定价重构。

核心指标：AI 模型的外部环境特征

Thinking：影响A股的重要宏观经济指标有哪些？

(1) 通胀双星：CPI & PPI

CPI (居民消费价格指数)：反映老百姓买东西贵不贵。CPI 过高意味着通胀，央行可能收紧银根（利空）。

PPI (工业生产者出厂价格指数)：反映工厂出货价。PPI 领先于 CPI，当 PPI 剧烈上涨而 CPI 不动时，意味着制造业中下游利润被压缩。

(2) 经济温度计：PMI

景气分水岭：50 是枯荣线。

AI 逻辑：如果 PMI 连续三个月站稳 50 以上且趋势向上，AI 会提高对周期性板块（钢铁、化工、有色）的配置权重。

工程难点：日期清洗

宏观数据来自不同官方机构，日期格式五花八门。

=> 这是代码中最核心的体力活

AI 模型需要的是一张整齐的表。如果日期对不上，你的 CPI 数据就会错位到上个月，导致 AI 学到错误的规律

=> 解决方法：Outer Join + COALESCE 写入

由于宏观指标的公布时间点不同（有的月更，有的日更），我们将它们合成为一张表：

- Outer Join (外连接)：保证即便某个指标本月还没公布，其他已公布的指标也能正常写入，不会丢失月份。
- SQL COALESCE 保护：

如果 AkShare 某次接口调用失败返回了 NULL，COALESCE 会确保数据库里原有的历史数据不会被抹除。

=> 让数据采集具备了容错能力。

工程难点：日期清洗

COALESCE 是 SQL 中的一个空值处理函数，它接受多个参数并返回第一个非 NULL 的值。

=> 这里它充当数据保镖，防止 AkShare 接口故障时把已有的好数据抹成空白。

```
COALESCE(value1, value2, ..., valueN)
```

从左到右检查，遇到第一个不是 NULL 的值就返回

如果全是 NULL，最终返回 NULL

```
SELECT COALESCE(NULL, NULL, '备用值', '其他');  -- 返回 '备用值'
SELECT COALESCE(0.05, 0.03);                    -- 返回 0.05（0 不是 NULL）
SELECT COALESCE(NULL, 0.03);                    -- 返回 0.03
```

Akshare使用

AKShare在宏观数据采集中的应用：

- 在代码中，你会看到大量的 ak.macro_china_... 调用。
- AkShare是一个免费、开源的 Python 库，封装了成百上千个金融接口。

底层：它本质上是在模拟你的浏览器去爬取统计局、央行等官网，并把混乱的网页解析成 Python 最好处理的 DataFrame。

Summary（宏观经济数据采集）

Step1，调用 AkShare：

分别拉取 CPI、PPI、PMI、M2、社融、LPR、10年期国债收益率等宏观指标。

Step2，解析与整理：

统一解析各类日期格式（如 2026年01月、202601），并提取同比、指标值，整理为标准 DataFrame。

Step3，合并月度指标：

将 CPI、PPI、PMI、M2、社融、LPR 按月做 outer join，只保留近 10 年数据。

Step4，写入主表：

通过 INSERT ... ON DUPLICATE KEY UPDATE 写入 trade_macro_indicator，使用 COALESCE 避免覆盖已有非空值。

Step5，国债收益率：单独写入 trade_rate_daily 表。

3-宏观经济数据采集.py

打卡：宏观经济数据采集

使用你的akshare进行宏观经济数据采集

- 这里会使用 数据表 trade_macro_indicator (月度宏观)

id	indicator_date	cpi_yoy	ppi_yoy	pmi	m2_yoy	data_source	created_at
1	2016-02-29	2.30	-4.90	49.00	13.30	akshare	2026-02-22 21:01:07
2	2016-03-31	2.30	-4.30	50.20	13.40	akshare	2026-02-22 21:01:07
3	2016-04-30	2.30	-3.40	50.10	12.84	akshare	2026-02-22 21:01:07
4	2016-05-31	2.00	-2.80	50.10	11.81	akshare	2026-02-22 21:01:07
5	2016-06-30	1.90	-2.60	50.00	11.78	akshare	2026-02-22 21:01:07
6	2016-07-31	1.80	-1.70	49.90	10.22	akshare	2026-02-22 21:01:07
7	2016-08-31	1.30	-0.80	50.40	11.35	akshare	2026-02-22 21:01:07
8	2016-09-30	1.90	0.10	50.40	11.50	akshare	2026-02-22 21:01:07
9	2016-10-31	2.10	1.20	51.20	11.64	akshare	2026-02-22 21:01:07
10	2016-11-30	2.30	3.30	51.70	11.39	akshare	2026-02-22 21:01:07
11	2016-12-31	2.10	5.50	51.40	11.33	akshare	2026-02-22 21:01:07
12	2017-01-31	2.50	6.90	51.30	10.70	akshare	2026-02-22 21:01:07
13	2017-02-28	0.80	7.80	51.60	10.40	akshare	2026-02-22 21:01:07
14	2017-03-31	0.90	7.60	51.80	10.10	akshare	2026-02-22 21:01:07
15	2017-04-30	1.20	6.40	51.20	9.80	akshare	2026-02-22 21:01:07
16	2017-05-31	1.50	5.50	51.20	9.10	akshare	2026-02-22 21:01:07
17	2017-06-30	1.50	5.50	51.70	9.10	akshare	2026-02-22 21:01:07
18	2017-07-31	1.40	5.50	51.40	8.90	akshare	2026-02-22 21:01:07

CASE：新闻事件采集与分析

新闻事件采集与分析

Thinking：为什么 AI 量化要读新闻?

传统策略往往在价格变动后才做出反应，而新闻往往是价格变动的诱因。

- 捕捉超额收益 (Alpha)

通过AI大模型识别出重大突破、战略合作等关键词，在市场还没完全反应过来时提前布局。

- 风险预警

当某只股票的负面新闻（如“违规”、“处罚”、“暴雷”）突然激增，AI 可以自动触发止损逻辑。

- 理解情绪

市场有时是不理性的。通过分析全市场的新闻情绪，AI 能判断当前是贪婪还是恐惧。

在量化交易的世界里，如果价格和财务数据是冷冰冰的数字，那么新闻和舆情就是带温度的情报。

情感分析：从关键词到语义理解

Thinking：如何知道一条新闻是好，还是坏？

方案 A：关键词匹配

通过预设的利好和利空词库进行打分。

- 利好词：涨停、超预期、增长、中标。
- 利空词：大跌、减持、亏损、处罚。

方案 B：大语言模型 (LLM)

使用 Qwen 或 DeepSeek 进行深度阅读。

- 优势：能理解明褒实贬的讽刺，或者复杂的逻辑（例如“营收增长但增速放缓”）。
- 现实考量：全量 A 股每天产生海量新闻，全部用大模型处理成本极高。
- 实战策略：先用关键词粗筛，再对重要新闻调用大模型精读。

工业级采集的坑与优化

在处理 5000 只股票的新闻采集时，代码设计必须考虑以下细节：

(1) 标题去重

同一条新闻（如“今日白酒板块表现强劲”）可能会出现在茅台、五粮液等多只股票的公告栏里。

策略：在写入数据库前，先检查标题是否已存在。如果存在，则跳过，避免数据库被无用信息撑爆。

(2) 多线程的限速艺术

为了提速，我们开启了 8 个线程并行采集 => 线程太多容易被服务器封禁 IP。

线程锁 (_print_lock)：在多线程同时打印进度时，如果不加锁，控制台输出会乱作一团。

(3) 增量跳过逻辑

代码会自动查询今天已经采集过的股票：

这样即便脚本意外中断，重启后也能从断点处继续，不会做无用功。

Summary（新闻事件采集）

Step1，获取采集列表

从 trade_stock_daily 取得全量股票，排除当日已采集过的股票。

Step2，拉取新闻

调用 AkShare 的 stock_news_em，按股票代码获取东方财富个股新闻，解析标题、内容、链接、来源等。

Step3，情感与重要性判断

基于关键词判断情感（利好 / 利空 / 中性）及是否重要事件。

Step4，去重与入库

按标题去重，若标题已存在则跳过，否则写入 trade_stock_news。

这里使用了并行采集，使用 8 线程的 ThreadPoolExecutor 并发采集。

4-新闻事件采集.py

Summary（新闻事件采集）

==========

新闻事件采集（全量A股）

==========

全量股票: 5191 只

跳过当日已采集: 323 只, 待采集: 4868 只

开始采集 (8 线程)...

[200/4868] 4.1% | 1.6/s | ETA 2981s | fetched 1940 saved 1

全量运行时间比较长，可以让AI改成你关心的股票列表

4-新闻事件采集.py

打卡：新闻事件采集

使用你的akshare进行新闻事件采集

- 这里会使用 数据表 trade_stock_news (个股新闻)

id	stock_code	news_type	title	content	source	source_url	published_at	sentiment
1339	000534.SZ	news	医药生物行业今日净流出资	（数据宝）	证券时报网	http://finance.eastmoney	2026-02-09 16:42:23	neutral
1343	000534.SZ	news	收盘价创历史新高股一览	建筑装饰 00	证券时报网	http://finance.eastmoney	2026-02-04 23:40:25	positive
1344	000534.SZ	news	83只股涨停 最大封单资金4	14620.81 基	证券时报网	http://finance.eastmoney	2026-02-03 16:15:35	positive
1345	000534.SZ	news	强势股追踪 主力资金连续5	金田股份 7	证券时报网	http://finance.eastmoney	2026-01-27 17:08:31	neutral
1346	000534.SZ	news	强势股追踪 主力资金连续5	金田股份 6	证券时报网	http://finance.eastmoney	2026-01-26 17:20:48	neutral
1347	000536.SZ	news	华映科技：2025年预亏9.8	1月28日，华	财中社	http://finance.eastmoney	2026-01-28 18:30:48	neutral
1348	000536.SZ	news	华映科技：预计2025年亏扌	中证智能财讯	中国证券报·中证	http://finance.eastmoney	2026-01-28 20:14:45	negative
1349	000536.SZ	news	华映科技股东华映百慕大减	1月19日，华	财中社	http://finance.eastmoney	2026-01-19 17:27:44	negative
1350	000536.SZ	news	历时7年，获偿逾30亿！00	历时约7年，	上海证券报	http://finance.eastmoney	2025-12-13 18:32:05	neutral
1352	000536.SZ	news	华为手机概念下跌1.30%，	1.34 -7763.	证券时报网	http://finance.eastmoney	2025-12-18 16:43:42	neutral
1353	000536.SZ	news	华映科技：终审胜诉 获赔3	12月12日，	每日经济新闻	http://finance.eastmoney	2025-12-12 20:39:04	neutral
1354	000536.SZ	news	华映科技：拉扯超7年 30亿	12月12日，	财中社	http://finance.eastmoney	2025-12-12 21:09:59	neutral
1355	000536.SZ	news	63.40亿元资金今日流入电	14627.71 6	证券时报网	http://finance.eastmoney	2025-12-17 17:39:59	neutral
1356	000536.SZ	news	4年合计近42亿元亏损"窟窿	12月12日晚	深圳商报·读创	http://finance.eastmoney	2025-12-12 22:44:27	negative
1357	000537.SZ	news	73只股中线走稳 站上半年	迦南智能 1.	证券时报网	http://finance.eastmoney	2026-02-12 11:47:53	neutral
1362	000537.SZ	news	融资客看好1股 买入占成交	2684.94 94	证券时报网	http://finance.eastmoney	2026-02-02 10:56:40	neutral
1363	000537.SZ	news	绿发电力：2025年净利同比	中证智能财讯	中国证券报·中证	http://finance.eastmoney	2026-01-30 20:46:31	neutral
1364	000537.SZ	news	绿发电力：公司合资项目主	绿发电力（0	每日经济新闻	http://finance.eastmoney	2026-01-22 17:44:11	neutral
1365	000537.SZ	news	绿发电力：2025年完成发电	人民财讯1月	人民财讯	http://finance.eastmoney	2026-01-16 17:18:29	neutral
1366	000538.SZ	news	云南白药：子公司拟1.37亿	人民财讯2月	人民财讯	http://finance.eastmoney	2026-02-10 18:25:39	neutral
1367	000538.SZ	news	云南白药股东新华都质押67	2月3日，云	财中社	http://finance.eastmoney	2026-02-03 19:03:39	neutral

CASE：机构研报采集

研报里的金矿：评级、目标价与预测

研报不仅仅是几页 PDF，对于 AI 模型来说，它提供了三个核心的非价格特征：

- 投资评级：买入、增持、中性、减持、卖出。
- 目标价格：分析师认为该股票在未来 6-12 个月内应该达到的价格。
- 盈利预测：对未来 1-3 年 EPS（每股收益）和净利润的量化预测。

注意分析师偏见：由于行业潜规则，分析师很少给出卖出评级。因此，当一家公司长期被评为买入，某天突然降为中性时，这其实是一个强烈的看空信号。

观点变化去重

Thinking：为什么券商的观点需要去重？

同一家券商为了刷存在感，会在“行业晨报”、“白酒周报”、“茅台深度报告”里反复提到同一个观点。

噪音：10 条记录，评级全是买入，目标价全是2200。

信号：第 11 条记录，评级依然是买入，但目标价调高到了2500。

Thinking：代码逻辑如何实现？

代码逻辑不是简单的删除重复，而是 只记录变化。

- 加载状态机：查询数据库，拿到每家券商对该股的最新一次观点。
- 触发器：只有当新采集到的评级或目标价与数据库里的不同时 => 才认为是一条有效的新增记录。

研报数据的量化实战因子

有了清洗后的干净数据，我们可以构建两个高价值的AI量化因子：

(1) 一致预期偏离度因子

Deviation = (Actual_EPS - Consensus_EPS) / Consensus_EPS

逻辑：股价不是由好消息驱动的，而是由比预期更好的消息驱动的。

应用：如果实际财报公布的 EPS 远超分析师一致预期，股价往往会迎来一波巨大的超预期上涨。

(2) 目标价空间因子

Upside = (Target_Price - Current_Price) / Current_Price

逻辑：衡量当前股价与专业人士眼中的合理价之间有多少肉。

策略示例：在 AI 选股模型中，我们可以给 目标空间 > 20%且近期评级上调的股票增加权重。

工程优化

研报数据不像行情数据那样秒变。

7 天跳过：代码中通过 DATE_SUB(NOW(), INTERVAL 7 DAY) 查询，如果这只股票在过去 7 天内已经采集过，就直接跳过。

=> 降低了对 AkShare 接口的请求频率，避免被封 IP，同时也保证了数据采集的高效率。

Summary（研报数据采集）

Step1，获取股票列表：从 trade_stock_daily 取全量股票，排除近 7 天已有研报的股票。

Step2，机构评级：

调用 AkShare 的 stock_institute_recommend_detail，从东方财富获取券商、评级、目标价、报告日期等。

Step3，去重：同一券商对同一股票，只保留评级或目标价发生变化的记录，避免重复录入。

Step4，盈利预期：调用 stock_profit_forecast_ths，从同花顺获取 EPS、净利润一致预期及覆盖机构数。

Step5，入库

写入 trade_report_consensus，使用 ON DUPLICATE KEY UPDATE。

机构评级写入 source_file='eastmoney'，一致预期写入 ths_consensus。

这里使用了并行采集，使用 4 线程的 ThreadPoolExecutor 并发采集。

全量运行时间比较长，可以让AI改成你关心的股票列表

5-研报数据采集.py

打卡：研报数据采集

使用你的akshare进行研报数据采集

- 这里会使用 数据表 trade_report_consensus (机构研报)

id	stock_code	broker	report_date	rating	target_price	eps_f	eps_foreca:	revenue_	source_file	created_at
2	600519.SH	长江证券	2026-02-22	买入	(Null)	Null)	(Null)	(Null)	eastmoney	2026-02-22 21:15:37
4	600519.SH	广发证券	2026-02-14	买入	1822.03	Null)	(Null)	(Null)	eastmoney	2026-02-22 21:15:37
5	600519.SH	招商证券	2026-02-12	买入	(Null)	Null)	(Null)	(Null)	eastmoney	2026-02-22 21:15:37
6	600519.SH	华泰证券	2026-02-11	买入	1920.24	Null)	(Null)	(Null)	eastmoney	2026-02-22 21:15:37
7	600519.SH	申万宏源研究	2026-02-10	买入	(Null)	Null)	(Null)	(Null)	eastmoney	2026-02-22 21:15:37
8	600519.SH	国泰海通证券	2026-02-08	买入	(Null)	Null)	(Null)	(Null)	eastmoney	2026-02-22 21:15:37
9	600519.SH	中金公司	2026-02-04	买入	1860.00	Null)	(Null)	(Null)	eastmoney	2026-02-22 21:15:37
10	600519.SH	海通国际	2026-02-04	买入	(Null)	Null)	(Null)	(Null)	eastmoney	2026-02-22 21:15:37
11	600519.SH	方正证券	2026-02-03	买入	(Null)	Null)	(Null)	(Null)	eastmoney	2026-02-22 21:15:37
12	600519.SH	华创证券	2026-02-03	买入	2600.00	Null)	(Null)	(Null)	eastmoney	2026-02-22 21:15:37
19	600519.SH	开源证券	2026-01-28	买入	(Null)	Null)	(Null)	(Null)	eastmoney	2026-02-22 21:15:37
22	600519.SH	国信证券	2026-01-26	买入	(Null)	Null)	(Null)	(Null)	eastmoney	2026-02-22 21:15:37
24	600519.SH	群益证券(香港)	2026-01-22	中性	1525.00	Null)	(Null)	(Null)	eastmoney	2026-02-22 21:15:37
25	600519.SH	华龙证券	2026-01-22	增持	(Null)	Null)	(Null)	(Null)	eastmoney	2026-02-22 21:15:37
27	600519.SH	西南证券	2026-01-20	买入	(Null)	Null)	(Null)	(Null)	eastmoney	2026-02-22 21:15:38
30	600519.SH	中邮证券	2026-01-15	买入	(Null)	Null)	(Null)	(Null)	eastmoney	2026-02-22 21:15:38
31	600519.SH	浙商证券	2026-01-15	买入	(Null)	Null)	(Null)	(Null)	eastmoney	2026-02-22 21:15:38
33	600519.SH	国泰海通证券	2026-01-14	买入	2005.84	Null)	(Null)	(Null)	eastmoney	2026-02-22 21:15:38

CASE：财经日历采集

财经日历采集

Thinking：财经日历对AI量化的作用是什么？

普通的财经数据确实很难直接产生超额收益（Alpha），因为它们太透明了。

但对于量化交易员来说，财经日历有两个不可替代的价值：

- 风险规避

在重大数据公布前（如非农、LPR），量化模型通常需要降低仓位，防止剧烈波动引发的爆仓或大幅回撤。

- 为 LLM 提供时间坐标

告诉 AI “今天是什么日子”，更精准地去抓取相关的解读。

财经日历：交易者的天气预报

如果说 K 线图是过去轨迹的记录，那么财经日历就是对未来波动率大爆发的预告。它不仅仅是排期表，更是全球资金流动的节奏器。

核心逻辑：预期差（Surprise）

实际走势 = 现实数据 − 市场预期

场景	数据表现	市场反应	逻辑
超预期	实际 > 预期	剧烈波动	市场需要迅速修正之前的错误定价
符合预期	实际 ≈ 预期	波动平缓	价格已经提前Price in（利好出尽）
不及预期	实际 < 预期	反向波动	市场信心受损，触发止损盘

A 股实战：哪些是一级警报？

Thinking：在 A 股做量化，你不能只看个股，还需要注意哪些要公布的指标？

- LPR（贷款市场报价利率）： 每月 20 日。直接影响房地产和银行板块的命根子。
- 社融/M2 数据： 每月中旬。这是 A 股的水龙头，水多了（流动性好）股市才容易涨。
- PMI（采购经理指数）： 每月底。这是经济好坏的体温计，50 是荣枯线。
- 美联储议息（FOMC）： 虽然是美国的，但它决定了北向资金（外资）是流入还是逃离 A 股。

有些人看到 CPI 上涨就觉得是好事（经济活跃），但在量化逻辑里，CPI 过高可能引发加息预期，反而是股市的利空。

代码实现：自动化采集流水线

```
import akshare as ak
import pandas as pd
from datetime import date, timedelta
def get_market_calendar(target_date):
    """
    抓取指定日期的财经日历，过滤出高价值信息
    """
    try:
        # 获取百度财经日历
        df = ak.news_economic_baidu(date=target_date)

        # 1. 筛选重要性为 3 星的事件（核心催化剂）
        high_impact = df[df['重要性'] == '3']

        # 2. 增加“预期差”计算列
        # 注：实际操作中需要处理百分比字符转浮点数
        return high_impact
    except Exception as e:
        print(f"采集失败: {e}")
        return pd.DataFrame()

# 示例：抓取未来一周的“大日子”
today = date.today().strftime('%Y%m%d')
print(f"正在扫描 {today} 的高敏感财经事件...")
```

这里使用 AkShare 库来对接百度财经的日历接口。

=> 自动筛选出3 星重要的事件，作为量化系统的预警输入。

6-财经日历采集.py

Summary（财经日历采集）

Step1，拉取数据：

调用 AkShare 的 news_economic_baidu()，按天拉取 前 7 天 ~ 后 30 天的财经事件（如 FOMC、CPI、非农等）。

Step2，过滤国家：

只保留中国、美国、欧元区、日本、英国的事件。

Step3，字段与分类：

从返回数据中提取日期、时间、国家、事件名、实际值、预期、前值、重要性；按事件名关键词将事件分为利率、通胀、就业、PMI、GDP 等类别。

Step4，入库：

写入 trade_calendar_event，使用 INSERT ... ON DUPLICATE KEY UPDATE 和 COALESCE，更新实际/预期/前值等字段但不覆盖已有有效值，数据来源记为 baidu_economic。

6-财经日历采集.py

打卡：财经日历采集

使用你的akshare进行研报数据采集

- 这里会使用 数据表 trade_calendar_event (财经日历)

id	event_date	event_time	country	category	title	importance	previous_value	source	status
1	2025-11-26	00:30	美国	other	美国11月25日12个月期国	1	528.02	baidu_economic	upcoming
2	2025-11-26	00:30	美国	other	美国11月25日12个月期国	1	42.51	baidu_economic	upcoming
3	2025-11-26	00:30	美国	other	美国11月25日12个月期国	1	3.21	baidu_economic	upcoming
4	2025-11-26	00:30	美国	interest_rate	美国11月25日12个月期国	1	3.45	baidu_economic	upcoming
5	2025-11-26	02:00	美国	other	美国11月25日5年期国债竞	1	700.0	baidu_economic	upcoming
6	2025-11-26	02:00	美国	other	美国11月25日5年期国债竞	1	2.38	baidu_economic	upcoming
7	2025-11-26	02:00	美国	other	美国11月25日5年期国债竞	1	40.3	baidu_economic	upcoming
8	2025-11-26	02:00	美国	monetary	美国10月季调后货币供应M	1	189128.0	baidu_economic	upcoming
9	2025-11-26	02:00	美国	monetary	美国10月季调后货币供应M	1	222125.0	baidu_economic	upcoming
10	2025-11-26	02:00	美国	other	美国11月25日5年期国债竞	1	3.63	baidu_economic	upcoming
11	2025-11-26	03:00	美国	other	美国11月25日2年期FRN浮	1	0.19	baidu_economic	upcoming
12	2025-11-26	03:00	美国	other	美国11月25日2年期FRN浮	1	21.8	baidu_economic	upcoming
13	2025-11-26	03:00	美国	other	美国11月25日2年期FRN浮	1	3.63	baidu_economic	upcoming
14	2025-11-26	03:00	美国	other	美国11月25日2年期FRN浮	1	300.0	baidu_economic	upcoming
15	2025-11-26	05:30	美国	other	美国截至11月21日当周AP	1	-31.7	baidu_economic	upcoming
16	2025-11-26	05:30	美国	other	美国截至11月21日当周AP	2	444.8	baidu_economic	upcoming
17	2025-11-26	05:30	美国	other	美国截至11月21日当周AP	2	154.6	baidu_economic	upcoming
18	2025-11-26	05:30	美国	trade	美国截至11月21日当周AP	1	-33.6	baidu_economic	upcoming
19	2025-11-26	05:30	美国	trade	美国截至11月21日当周AP	1	39.6	baidu_economic	upcoming
20	2025-11-26	05:30	美国	other	美国截至11月21日当周AP	1	-79.0	baidu_economic	upcoming
21	2025-11-26	05:30	美国	other	美国截至11月21日当周AP	1	57.7	baidu_economic	upcoming

为什么标准数据还不够?

财经日历只能抓到定期体检报告（如每月一次的 CPI）。但 A 股很多时候是受突发会议/事件/政策 驱动的。

例如:

- 某次突然召开的国务院常务会议。
- 某个行业龙头的突发财报预警。
- 某位重量级人物在金融峰会上的讲话。

=> 这些非结构化的事件催化剂，是产生 Alpha（超额收益）的重要战场。

Thinking：如何捕捉到这些未来的催化剂事件?

CASE：大模型驱动的催化剂发现

从看新闻到抓先机

催化剂：量化交易的打火石

在量化领域，我们区分两种 Alpha（超额收益）：

- 分析 Alpha： 别人也看到数据，但我算得比别人快、比别人准。
- 信息 Alpha： 我看到了别人还没意识到的确定性未来。

=> 催化剂事件就是信息Alpha的核心。

从看新闻到抓先机

Thinking：普通财经新闻 和 催化剂事件的区别?

普通财经新闻：今日白酒板块大跌

催化剂事件：3月20日：春季糖酒会开幕，关注新品发布

维度	普通财经新闻	催化剂事件
时效性	滞后：描述已经发生的事实	超前：锁定未来必定发生的节点
信噪比	低：混杂了大量情绪和噪音	高：聚焦政策、规则、供需的转折点
确定性	不确定：新闻真假难辨	高：源于官方日程和公告

从看新闻到抓先机

Thinking：为什么必须用 LLM 联网搜索？

传统的 API（如 AkShare、Tushare）是结构化数据库，它们的局限在于：

- 盲区大： 很多影响股价的事件（如：中东局势的谈判日、某垂直行业的标准发布会）没有标准接口。
- 无逻辑： API 只给你一个日期，不告诉你为什么这个日期重要。

=> LLM 的价值： 它不仅是搜刮者，更是过滤器。

LLM能理解“低空经济”或“合成生物学”这些新词，并从互联网海量废话中精准提取出相关的关键会议、政策窗口和技术节点。

核心技术：Prompt 工程的模块化管理

在实际生产环境中，不要把 Prompt 写在代码里。我们使用 prompts.yaml 进行管理。

实战技巧：YAML 的优势

- 多行保留格式： 使用 | 符号，让 Prompt 像文章一样清晰，便于 LLM 理解复杂指令。
- 变量插值： 通过 Python 的 .format() 动态注入 start_date 和 end_date。

```
# prompts.yaml 节选
calendar:
 search_catalysts: |
  你是一位顶级的宏观策略分析师。请联网搜索并整理从 {start_date} 到 {end_date}
  可能对 A 股产生“定调性”或“脉冲性”影响的事件。
  你需要重点关注：
  1. 决策层动态：如政治局会议（4/7/10/12月）、中央经济工作会议。
  2. 产业节点：如华为/特斯拉的发布会、英伟达财报日、全球 AI 峰会。
  3. 市场规则：如 MSCI/富时罗素指数调整生效日。
  ...
```

流程设计：两阶段 LLM 调用

我们不是简单地搜一次就完了，而是采用了 发现 -> 预研 的两阶段模式。

第一步：发现

调用 LLM 联网，寻找未来 3-6 个月的大事件。这一步解决的是 What & When。

第二步：预研

针对搜到的每个事件，再次调用 LLM。不联网，但要求它基于专业知识生成一段 深度提问词（ai_prompt）。

数据清洗：解决 LLM 的幻觉与冗余

LLM 联网搜索虽然强大，但会有两个坑：

- 日期漂移： 比如把 3 月 5 日的两会写成 3 月 6 日。
- 措辞重复： 同一件事，搜索结果里可能有三个版本。

Thinking：如何基于时间窗口进行去重？

```
# 伪代码：判断是否为同一事件
def is_duplicate(new_event, existing_events):
    for ex in existing_events:
        # 如果标题相似度高，且日期相差在 5 天以内，视为同一催化剂
        if similarity(new_event.title, ex.title) > 0.8 and abs(new_event.date - ex.date) <= 5:
            return True
    return False
```

催化剂的量化应用示例

Thinking：采集到这些数据后，怎么赚到钱？

你可以构建以下策略：

- 波动率预警策略： 在美联储议息前 12 小时，自动平掉所有的杠杆合约，规避剧震。
- 事件驱动策略（Event-Driven）： 监测苹果发布会日期。

历史统计显示：发布会前 10 天，果链代工企业的超额收益概率为 65%。

执行： 提前 10 天买入相关 ETF。

LLM 自动化研究员： 每天早上 8 点，AI 自动根据今天的催化剂列表，生成一份《今日必看事件影响测算》发送邮件给你

Summary（关键催化剂采集）

Step1，联网搜索：

调用 Qwen Max（enable_search=True），搜索未来 6 个月对 A 股有重要影响的催化剂事件（如两会、FOMC、非农等），提示词从 prompts.yaml 读取。

Step2，解析事件：

从模型返回文本中解析出 JSON 数组，得到事件日期、标题、国家、类别、重要程度等字段。

Step3，生成 AI 提问：

分批（每批约 20 个事件）调用 Qwen，为每个事件生成一个“如何围绕该事件提问”的 prompt，保存到 ai_prompt。

Step4，去重入库：

按标题归一化后，如已存在相同标题且在 5 天内的记录则跳过；否则写入 trade_calendar_event，source='qwen_search'，importance 取 2 或 3。

7-关键催化剂采集.py

打卡：关键催化剂采集

使用你的LLM（比如Qwen Max）进行关键催化剂采集

- 这里会使用 数据表 trade_calendar_event (财经日历)

id	event_date	event_time	country	category	title	importance	ai_prompt	source
2341	2026-08-20	(Null)	美国	interest_rate	美联储FOMC议息会议	3	2026年8月20日美国将举行	qwen_search
2339	2026-08-07	(Null)	中国	inflation	CPI/PPI数据公布	2	2026年8月7日中国将公布(	qwen_search
2338	2026-08-01	(Null)	中国	pmi	PMI数据公布	2	2026年8月1日中国将公布I	qwen_search
2337	2026-07-20	(Null)	美国	interest_rate	美联储FOMC议息会议	3	2026年7月20日美国将举行	qwen_search
2335	2026-07-02	(Null)	美国	employment	非农就业报告	3	美国即将公布非农就业报告	qwen_search
2334	2026-07-01	(Null)	中国	pmi	PMI数据公布	2	2026年7月1日中国预计发	qwen_search
2332	2026-06-20	(Null)	美国	interest_rate	美联储FOMC议息会议	3	2026年6月20日美联储将召	qwen_search
2330	2026-06-01	(Null)	中国	pmi	PMI数据公布	2	2026年6月1日即将公布的I	qwen_search
2329	2026-05-20	(Null)	美国	interest_rate	美联储FOMC议息会议	3	2026年5月20日，美联储将	qwen_search
2324	2026-04-20	(Null)	美国	interest_rate	美联储FOMC议息会议	3	美联储FOMC议息会议(202	qwen_search
2322	2026-04-01	(Null)	中国	pmi	PMI数据公布	2	2026年4月1日，中国将公	qwen_search
2318	2026-08-23	(Null)	其他	monetary	MSCI指数调整生效	2	MSCI指数即将进行季度调	qwen_search
2317	2026-08-20	(Null)	中国	monetary	社融/M2数据发布	2	中国即将发布社融/M2数据	qwen_search
2316	2026-08-15	(Null)	中国	interest_rate	MLF/LPR利率公布	2	中国即将公布MLF/LPR利率	qwen_search
2315	2026-08-01	(Null)	中国	pmi	PMI数据发布	2	中国即将发布PMI数据，请	qwen_search
2314	2026-07-20	(Null)	中国	inflation	CPI/PPI数据发布	2	中国即将发布CPI/PPI数据，	qwen_search
2313	2026-07-15	(Null)	中国	interest_rate	MLF/LPR利率公布	2	2026年7月15日，中国将同	qwen_search
2312	2026-07-05	(Null)	美国	employment	非农就业报告	3	2026年7月5日，美国将公	qwen_search
2311	2026-07-01	(Null)	中国	policy	政治局会议	3	中国即将召开政治局会议，	qwen_search
2310	2026-06-20	(Null)	中国	monetary	社融/M2数据发布	2	2026年6月20日，中国将公	qwen_search
2309	2026-06-15	(Null)	中国	interest_rate	MLF/LPR利率公布	2	2026年6月15日中国将再次	qwen_search
2308	2026-06-01	(Null)	中国	pmi	PMI数据发布	2	2026年6月1日，中国将发	qwen_search

Charles的入职

Charles 为我们的 AI 模型构建了一个完整的特征库 。

Thinking：在一个交易日清晨，如何使用这些数据进行联动?

Step1. 扫描催化剂

每天早上 8:00，AI 首先调取 trade_calendar_event（表 7）和 关键催化剂 。

发现： 今天 20:30 美国公布非农就业数据，且下周有两会政策预期 。

逻辑： 财经日历提供了波动时间轴，而 LLM 生成的 ai_prompt 引导模型关注财政赤字率等核心变量 。

Step2，定位资金潮汐

接着 AI 检查 trade_macro_indicator（表 3）和 trade_rate_daily（表 4） 。

观测： 10 年期国债收益率近期持续飙升（定价之锚） 。

风险： AI 自动判定当前处于杀估值环境，即使个股财报再好，也需要警惕整体回调风险 。

Charles的入职

Step3. 筛选优质种子

AI 检索 trade_stock_financial（表 2），利用 Charles 编写的 函数过滤出盈利质量最高的股票。

筛选标准： ROE > 15 且 经营现金流/净利润 比率健康。

去伪存真： 剔除那些只有纸面富贵而无现金流支撑的公司。

Step4. 捕捉预期差与情绪因子

这是产生 Alpha 的关键点：结合 trade_stock_news（表 5）和 trade_report_consensus（表 6）。

- 计算偏离度：

$$Deviation = \frac{Actual_EPS - Consensus_EPS}{Consensus_EPS}$$

情报融合： 分析师刚调高了某半导体公司的评级，同时新闻舆情显示其自研芯片获得重大进展。

向量数据库在此刻完成了语义匹配，识别出这并非噪音，而是真实利好。

Charles的入职

Step5. 执行：回测与交易最后

所有分析落实到 trade_stock_daily（表 1）中 。

前复权处理： 确保技术指标（如均线、MACD）不因高送转而失真 。

换手率分析： 确认该股近期成交活跃，主力资金有进场迹象 。

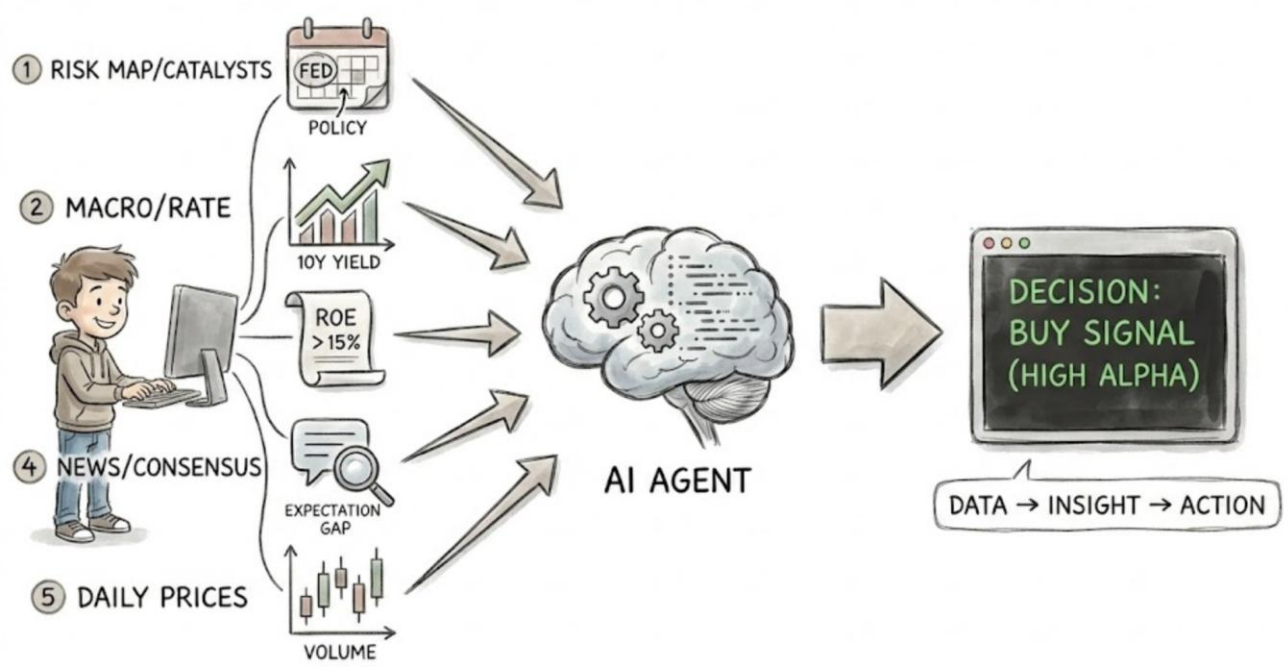

Thank You

Using data to solve problems